

Grafos de Conhecimento Centrados em Sessão HTTP para Detecção Explicável de DDoS

Natanael Oliveira^{a,*}, Arthur Kobielski^a, Marcos Luna^a

^a *Universidade Federal do Rio Grande do Sul, Porto Alegre, Brasil*

Abstract

Ataques distribuídos de Slow HTTP DoS sustentam taxas baixas por sessão e atravessam defesas baseadas em assinatura, limiares estatísticos e quotas por IP, sessão ou *token*. O sinal de ataque não está em nenhuma sessão isolada, mas na correlação estrutural entre sessões coordenadas. A literatura de detecção reduz a sessão a um vetor numérico antes do classificador e descarta exatamente essa estrutura, de modo que o detector não articula *por que* uma sessão é suspeita e perde o padrão *cross-session* que define a campanha. Trabalhos recentes em grafos de conhecimento aplicados à segurança de rede combinam o grafo com classificadores neurais e explicação pós-hoc, mostrando ganhos em explicabilidade, mas tratam o tráfego em nível de nó de rede (porta, IP) e não modelam a sessão HTTP como entidade semântica raciocinável; tampouco acoplam o veredicto a uma política de mitigação derivada do próprio grafo. Este artigo propõe um arcabouço que modela a sessão HTTP como objeto semântico de primeira classe em OWL, com relações tipadas para identidade do cliente, *endpoint* alvo, sinais comportamentais e mitigação aplicável, e alinhamento a STIX 2.1 e MITRE ATT&CK. Em particular, a relação que liga sessões entre si é refinada em uma família de sub-propriedades tipadas e ponderadas — `relatedByTLSPFingerprint`, `relatedByReusedIdentity`, `relatedByTemporalPattern`, `relatedByPayloadSignature`, `relatedByEndpointConvergence` e `relatedByNetworkProximity` —, refletindo o fato de que botnets modernas distribuem agressivamente em ASN e prefixo de IP, e que a coordenação real é discernível principalmente por *finger-*

*Autor correspondente

Email addresses: `natanael.oliveira@inf.ufrgs.br` (Natanael Oliveira), `arthur.kobielski@inf.ufrgs.br` (Arthur Kobielski), `marcos.luna@inf.ufrgs.br` (Marcos Luna)

print TLS, identidade reaproveitada e padrão temporal. Requisições são elevadas em tempo de execução a um grafo no qual regras em SPARQL/SWRL operam por soma ponderada das sub-relações e produzem veredictos com cadeias de evidência. O discriminador do *cluster* detectado é usado para derivar automaticamente o escopo da mitigação aplicada, preservando o tráfego legítimo. A avaliação parametriza a campanha pelo grau de distribuição, isola por ablação o ganho do raciocínio em nível de sessão, e introduz uma métrica de fração de tráfego legítimo afetada pela mitigação resultante. A implementação é disponibilizada como código aberto.

Keywords: Grafo de Conhecimento, Detecção de DDoS, Camada 7 HTTP, Sessão como Entidade Semântica, Raciocínio *Cross-Session*, IA Explicável

1. Introdução

1.1. Contexto e Motivação

Ataques de Negação de Serviço Distribuída (DDoS) na camada de aplicação mudaram qualitativamente na última década, e a escala recente é a evidência mais visível dessa mudança. O *survey* canônico de Tripathi e Hubballi reportou em 2021 que o volume de ataques de Camada 7 dobrava a cada trimestre, com um incidente sustentando 292.000 requisições por segundo durante treze dias [1]. Em agosto de 2023, o *HTTP/2 Rapid Reset* (CVE-2023-44487) inaugurou uma nova ordem de grandeza: Amazon Web Services, Cloudflare e Google divulgaram conjuntamente picos de 155, 201 e 398 milhões de requisições por segundo, respectivamente, mitigados naquele trimestre [2, 3, 4]. A operação que sustentou o pico de 398 milhões usou uma *botnet* de cerca de vinte mil máquinas — escala compatível com o que se observa rotineiramente em campanhas de Camada 7 sobre HTTP/HTTPS em 2024 e 2025, com mais de seis mil e quinhentos ataques *hyper-volumetric* bloqueados pela Cloudflare no segundo trimestre de 2025 (média de setenta e um ataques por dia) e crescimento de cento e vinte e nove por cento ano-a-ano especificamente em HTTP DDoS [5, 6].

A categoria central nesse novo regime é a família de **ataques distribuídos de Slow HTTP DoS**. Inclui Slowloris e seus descendentes diretos (slow body, slow read), suas variantes de alta taxa (HULK, GoldenEye), e os ataques modernos sobre HTTP/2, como Rapid Reset, CONTINUATION Flood e MadeYouReset. Adotamos a expressão *ataque distribuído de Slow HTTP DoS* (e não *Slow HTTP DDoS distribuído*) por razão de precisão: Slowloris e

suas variantes foram originalmente projetadas como ataques *single-source* [7], e a forma multi-origem coordenada que motiva este trabalho é precisamente uma variante *distribuída* da família. O denominador comum dessa família, em sua forma distribuída, é a *sub-limiaridade por sessão*: cada origem contribui pouco, o conjunto exaure o servidor. Vista isoladamente, cada requisição é indistinguível de uma legítima — estrutura, cabeçalhos e frequência são compatíveis com tráfego normal. O sinal de ataque mora no padrão de uso da sessão e, mais ainda, no padrão estrutural entre sessões: a duração das conexões mantidas pelo cliente, a entropia das rotas visitadas, a consistência do *fingerprint* do cliente, e a convergência de múltiplas origens no mesmo *endpoint* sob a mesma assinatura de cliente [8, 9, 10].

A literatura de detecção reconhece o problema, ao menos em parte. A meta-análise de Odusami et al. [11] sobre setenta e cinco estudos mostra que quarenta e sete por cento dos métodos usam *features* extraídas de sessões (taxa de requisições por usuário, duração média, contagem de operações por identidade). Em todos esses métodos, contudo, a sessão é reduzida a um vetor numérico antes de chegar ao classificador. O detector vê estatísticas, não vê a sessão. Não consegue, portanto, raciocinar sobre relações entre sessões, sobre identidades reaproveitadas, ou sobre padrões que só emergem quando duas sessões individualmente normais são analisadas em conjunto. Detectores recentes baseados em aprendizado de máquina para HTTP de Camada 7 reportam AUC (área sob a curva ROC) competitivo, mas seus autores admitem que a metodologia não foi validada em tempo real e que o resultado é binário, sem explicação ontológica [8].

Trabalhos contemporâneos buscam mitigar essa opacidade combinando representações em grafo com técnicas de IA explicável. Belcastro et al. [12] propõem o arcabouço KLAGÉ, que constrói grafos de conhecimento a partir de logs de rede, classifica nós via Graph-BERT, e gera relatórios em linguagem natural com auxílio de LIME e modelos de linguagem grandes. KLAGÉ inclui DDoS Slowloris entre os ataques avaliados e atinge $F1 = 84,1\%$ em *datasets* IoT de referência. Trata-se de evidência concreta de que o uso de grafos de conhecimento na detecção de tráfego anômalo se tornou prática viável. No entanto, o pipeline opera em nível de *nó de rede* (porta, IP, fluxo) em vez de modelar a sessão HTTP como entidade semântica raciocinável, captura coordenação entre nós implicitamente em *embeddings* aprendidos e não em relações simbólicas nomeadas, e termina no relatório textual sem articular uma política de mitigação cujo escopo seja derivado do próprio grafo. Esses três pontos delimitam a margem que o presente trabalho explora.

1.2. Definição do Problema

Tratamos a detecção de DDoS de Camada 7 sobre HTTP como um problema de *representação semântica de sessão*, e não de engenharia de features sobre estatísticas de sessão. A sessão HTTP é a unidade natural de comportamento de um cliente contra a aplicação. Também é o objeto que detectores existentes mais sumarizam e menos modelam semanticamente. Três deficiências do estado da arte motivam nossa abordagem:

1. **Sessão como *feature aggregate*, não como entidade.** A meta-análise de Odusami et al. [11] mostra que quarenta e sete por cento dos métodos de detecção de DDoS de Camada 7 usam estatísticas agregadas de sessão (taxa de requisições, duração, contagem de operações por identidade), mas nenhum dos setenta e cinco estudos catalogados trata a sessão como entidade semântica raciocinável, com identidade, alvo, comportamento e relações tipadas. Na prática, features de sessão viram números num vetor. O vetor não preserva o que torna a sessão útil em primeiro lugar: ela conecta múltiplas requisições, uma identidade, um endpoint alvo, e um histórico observável.
2. **Ausência de explicação ontológica.** Detectores baseados em aprendizado de máquina para ataques de Camada 7 HTTP reportam métricas competitivas, mas emitem rótulos binários sem fundamentação semântica. Os autores de um dos trabalhos mais recentes [8] notam explicitamente que sua metodologia não foi validada em tempo real e não produz explicação das decisões. Em operação real, um analista de segurança decide dezenas de vezes por hora entre bloquear um cliente, aplicar um desafio (*challenge*), ou degradar uma sessão. “Isto parece um ataque” não é decisão; é hesitação. A decisão exige saber qual endpoint está sob estresse, qual identidade está envolvida e qual sinal sustenta a hipótese.
3. **Ausência de raciocínio *cross-session* simbólico e ponderado.** Raciocínio *cross-session* é a capacidade de relacionar múltiplas sessões através de identificadores compartilhados do cliente, em vez de tratar cada sessão como caso independente. Campanhas distribuídas de Slow HTTP DoS envolvem K origens distintas mantendo conexões parciais ou sustentadas contra o mesmo *endpoint*, cada uma operando abaixo de qualquer limiar individual razoável. Cada sessão isolada tem assinatura fraca. O conjunto tem estrutura clara quando analisado em conjunto,

mas **nenhum identificador isolado basta**: *botnets* modernas distribuem agressivamente em ASN e prefixo de IP — a partir de dispositivos IoT comprometidos em milhares de provedores residenciais, frotas de *cloud instances*, ou *residential proxies* pagos. Sinais de proximidade de rede, portanto, são fracos por construção. A coordenação real, naquilo que a economia da operação força a manter correlacionado, aparece em outros eixos: o *fingerprint* TLS (assinatura computada a partir do *handshake* TLS, capaz de identificar o software cliente mesmo quando o IP de origem muda — JA3 e JA4 são as implementações conhecidas), o reaproveitamento de identidade (*cookie*, *username*, *token*), o padrão temporal (cadência, *jitter*, duração de conexão), a assinatura de *payload*, e a convergência em *endpoint* específico. Raciocínio *cross-session* adequado precisa, portanto, expressar esses múltiplos sinais como *relações tipadas distintas com pesos diferenciados*, e operar por soma ponderada, não por disjunção plana. Detectores que reduzem a sessão a *features* não conseguem articular isso. Arcabouços recentes baseados em redes neurais sobre grafos, como Graph-BERT em KLAGÉ [12], capturam parte dessa coordenação ao processar o grafo de tráfego, mas a relação entre sessões fica latente nos *embeddings*, sem expressão simbólica nomeada que possa ser auditada, consultada ou usada para derivar uma política de mitigação. Levantamentos recentes de grafos de conhecimento em cibersegurança [13] já reconheciam a lacuna: “*ainda é pouco explícito como implementar o grafo de conhecimento para enfrentar dificuldades industriais reais em situações de ciberataque e defesa*”. KGs construídos a partir de texto de inteligência de ameaças não capturam estrutura de tráfego em tempo de execução, e KGs alimentados em runtime por classificadores neurais entregam o veredicto mas não a justificativa formal que sustenta decisões de mitigação cirúrgica.

1.3. Questões de Pesquisa

Este trabalho aborda as seguintes questões de pesquisa:

- QP1:** Como uma ontologia OWL pode modelar a sessão HTTP, junto a *endpoint*, identidade e comportamento, com fidelidade suficiente para sustentar raciocínio sobre ataques distribuídos de Slow HTTP DoS em vez de meramente agregar *features* ao nível de sessão?
- QP2:** Como representar a relação *cross-session* de forma que reflita o fato de que sinais diferentes têm robustez diferente a evasão (*fingerprint*

TLS, padrão temporal e identidade reaproveitada como sinais primários; proximidade de rede como auxiliar), e quais regras semânticas operam sobre essa estrutura para detectar ataques sub-limiares por sessão individual?

QP3: Como as decisões de detecção resultantes podem ser apresentadas como cadeias de evidências explícitas que enumeram as sub-relações ativadas e seus pesos, em formato auditável por analistas de segurança e exportável em padrões abertos (JSON-LD, STIX 2.1)?

QP4: Qual é o ganho empírico do raciocínio semântico em nível de sessão sobre detecção baseada em *features* agregadas, controlando para o mesmo conjunto subjacente de atributos de tráfego, e qual a fração de tráfego legítimo afetado pela mitigação resultante — métrica até onde verificamos não usada sistematicamente na literatura acadêmica de detecção de Camada 7?

1.4. Contribuições

Este trabalho não reivindica o uso pioneiro de grafos de conhecimento em detecção de ameaças; trabalhos como KLAGÉ [12] já demonstraram a viabilidade dessa abordagem. As contribuições deste artigo localizam-se em outro eixo, com quatro componentes principais:

1. **Sessão HTTP como entidade ontológica de primeira classe, com família `relatedTo` ponderada.** Uma ontologia OWL que modela a classe `ApplicationSession` com relações tipadas para identidade do cliente (`hasIdentity`), *endpoint* alvo (`targets`), comportamento exibido (`exhibitsBehavior`) e mitigação aplicável (`mitigatedBy`). Em vez de uma única relação `relatedTo`, a ontologia formaliza uma *família* de seis sub-propriedades tipadas e ponderadas — `relatedByTLSPFingerprint`, `relatedByReusedIdentity` e `relatedByTemporalPattern` de peso alto; `relatedByPayloadSignature` e `relatedByEndpointConvergence` de peso médio; `relatedByNetworkProximity` de peso baixo. Essa distinção reflete o fato operacional de que *botnets* modernas distribuem agressivamente em ASN e prefixo de IP, e a coordenação real é discernível principalmente pelos sinais de peso alto. A ontologia formaliza a família de *ataques distribuídos de Slow HTTP DoS* como ataque de referência, com hierarquia que comporta variantes de conexão sustentada e variantes baseadas em taxa. Diferentemente de abordagens baseadas

em grafos como KLAGÉ [12], que operam em nível de nó de rede (porta, IP, fluxo), a unidade de raciocínio aqui é a sessão de aplicação. A ontologia mantém alinhamento com STIX 2.1 e MITRE ATT&CK.

2. **Raciocínio simbólico nativo sobre soma ponderada das sub-relações.** Um *pipeline* que eleva requisições HTTP a instâncias ontológicas, populando sessões como nós persistentes do grafo, com cada sub-propriedade de `relatedTo` instanciada independentemente a partir de seu sinal específico (assinatura TLS, identidade observada, padrão temporal, *payload*, convergência em *endpoint*, proximidade de rede). As regras de detecção, formuladas em SPARQL e SWRL e avaliadas por um *reasoner* OWL, operam por *soma ponderada* das sub-relações: o *cluster* se sustenta sobre a combinação dos sinais robustos, sem depender de nenhum identificador isolado. O veredicto é a derivação simbólica que satisfaz a regra, não a saída de um classificador interpretado a posteriori. Esse desenho contrasta tanto com KGs estáticos construídos a partir de texto de inteligência de ameaças [14, 15] quanto com abordagens neurais que classificam o grafo e explicam o resultado via técnicas pós-hoc [12].
3. **Cadeia de evidência simbólica acoplada à derivação automática de escopo de mitigação.** Quando uma regra dispara, o motor emite um veredicto acompanhado por uma cadeia de evidência exportável em JSON-LD e STIX 2.1, contendo as instâncias ontológicas envolvidas, as sub-relações ativadas, seus pesos e os valores que satisfizeram a regra. A partir do conjunto mínimo de propriedades compartilhadas pelas sessões do *cluster*, o arcabouço deriva automaticamente o escopo da política de mitigação aplicada (tipicamente o par (*fingerprint TLS*, *padrão de endpoint*), eventualmente reforçado por padrão temporal), em contraste com defesas que aplicam controle global na rota e afetam tráfego legítimo. Esse acoplamento entre detecção, evidência e mitigação não é tratado por arcabouços acadêmicos contemporâneos baseados em KG [12], que terminam no relatório textual.
4. **Avaliação parametrizada pelo grau de distribuição, com ablação por sub-grupo de sinais e métrica de dano colateral.** A avaliação isola, por ablação sobre o mesmo conjunto subjacente de atributos de tráfego, três contribuições: (i) o ganho de qualquer raciocínio *cross-session* (família `relatedTo` completa) sobre *baselines* de aprendizado de máquina que consomem *features* agregadas; (ii) o ganho específico dos sinais de peso alto (TLS, identidade, temporal) sobre

o subgrupo apenas com sinais de peso médio/baixo, evidenciando que ASN/prefixo de IP não basta; (iii) o impacto sobre o tráfego legítimo, medido pela fração afetada pela mitigação resultante. Essa métrica é auto-reportada por produtos comerciais de *bot management* sem benchmark acadêmico público e não é usada sistematicamente na literatura de detecção de Camada 7. Uma implementação de referência em código aberto do *pipeline* completo é disponibilizada, endereçando a lacuna de implementação operacional quantificada por Odusami et al. [11].

1.5. Organização do Artigo

O restante deste artigo está organizado como segue. A Seção 2 revisa trabalhos relacionados em grafos de conhecimento para cibersegurança, em detecção de DoS de Camada 7 sobre HTTP, e em modelagem de sessão para detecção de anomalias, posicionando nossa contribuição em relação às abordagens existentes mais próximas. A Seção 3 apresenta o arcabouço proposto, incluindo o *design* da ontologia centrada em sessão, o *pipeline* de construção do grafo de conhecimento em tempo de execução, e a regra de detecção semântica baseada em soma ponderada das sub-relações **relatedBy**. A Seção 4 descreve a metodologia experimental, com ataques distribuídos de Slow HTTP DoS como caso instanciado, o conjunto de dados, os *baselines* baseados em *features* agregadas, e as métricas (incluindo dano colateral em tráfego legítimo). A Seção 5 relata e discute os resultados, com ênfase na ablação que isola tanto o ganho do raciocínio em nível de sessão quanto o ganho específico dos sinais de peso alto sobre o subgrupo de proximidade de rede. A Seção 6 conclui e delinea direções para extensão, incluindo a operacionalização das classes **CredentialStuffing** e **CoordinatedAPIAbuse** já comportadas pela ontologia mas fora do escopo experimental atual.

2. Trabalhos Relacionados

2.1. Grafos de Conhecimento em Cibersegurança

A primeira onda de trabalhos em grafos de conhecimento aplicados à cibersegurança privilegiou a construção *estática* do grafo a partir de texto de inteligência de ameaças. Jia et al. [14] consolidaram um arcabouço prático em que entidades de CVEs, relatórios e *blogs* são extraídas, normalizadas e ligadas para produzir uma base de conhecimento consultável, útil para enriquecimento e correlação após o fato. Bonagiri et al. [15] reforçaram essa linha em 2024 com aplicações práticas em problemas reais de segurança, mantendo

a mesma premissa: o grafo é um registro do que já se sabe sobre ameaças, alimentado por texto e atualizado periodicamente. O levantamento de Liu et al. [13] sintetizou o estado da área e reconheceu explicitamente a lacuna entre a sofisticação do modelo e o uso operacional: “ainda é pouco explícito como implementar o grafo de conhecimento para enfrentar dificuldades industriais reais em situações de ciberataque e defesa”.

Trabalhos contemporâneos passaram a explorar grafos populados em tempo de execução a partir do próprio tráfego, com classificadores neurais sobre o grafo e técnicas de IA explicável acopladas. O exemplar mais próximo dessa linha é KLAGÉ, proposto por Belcastro et al. [12]. KLAGÉ constrói grafos de conhecimento a partir de logs e fluxos de rede, classifica nós com Graph-BERT, gera explicações com LIME e produz relatórios em linguagem natural por meio de modelos de linguagem grandes. Avaliado em *datasets* IoT de referência (RT-IoT2022 e CIC-IoT2023) sobre seis ataques — entre eles DDoS Slowloris — KLAGÉ atinge $F_1 = 84,1\%$, supera *baselines* GNN e BERT-based e disponibiliza código aberto. É a evidência mais clara de que grafos de conhecimento podem servir como mecanismo de detecção em runtime, e não apenas como registro pós-fato.

O presente trabalho parte da mesma premissa de runtime e diverge em três eixos. Primeiro, a unidade de raciocínio em KLAGÉ é o *nó de rede* (porta, IP, fluxo); aqui é a *sessão HTTP*, modelada como entidade ontológica de primeira classe, com identidade composta (*cookie*, *token*, *username*, *fingerprint* TLS). Segundo, KLAGÉ encode o grafo via *embeddings* aprendidos (Graph-BERT) e explica a saída com LIME pós-hoc; este trabalho usa OWL com regras simbólicas em SPARQL/SWRL, e o veredicto é a derivação que satisfaz a regra. Terceiro, KLAGÉ termina no relatório textual; este trabalho deriva, a partir do discriminador do *cluster* detectado, o escopo da política de mitigação aplicada.

2.2. Detecção de Ataques DDoS de Camada 7 sobre HTTP

A detecção de DDoS na camada de aplicação HTTP organiza-se historicamente em três famílias. A primeira é o perfilamento estatístico de tráfego e sessão. Fernandes et al. [10] construíram perfis autônomos a partir de análise por componentes principais (PCA) sobre estatísticas agregadas de fluxo, com aplicação direta à detecção de anomalias em redes operacionais. Bharathi e Sukanesh [9] aplicaram a mesma ferramenta, PCA, a uma matriz comportamental por sessão, oferecendo uma das primeiras formulações que coloca a

sessão no centro — ainda que como vetor de *features* agregadas, e não como entidade.

A segunda família agrega *features* de fluxo ou de sessão e as entrega a classificadores supervisionados. Kemp et al. [8] é o representante mais recente: emprega *Random Forest* e SVM sobre vetores de sessão e reporta AUC competitivo. Os autores notam explicitamente, no entanto, que a metodologia não foi validada em tempo real e que a saída é binária, sem explicação ontológica das decisões. Esta limitação é representativa da família: o classificador aprende a separar conjuntos no espaço de *features*, mas perde a estrutura entre sessões que justifica a separação.

A terceira família consolida o domínio em levantamentos de escala. Tripathi e Hubballi [1] sintetizaram em 2021 o estado da detecção e defesa em DDoS de camada de aplicação, com a observação — citada na Seção 1 — de que o volume de Camada 7 dobrava a cada trimestre. A taxonomia de Slow DoS Attacks de Cambiaso et al. [7] permanece como referência formal para a categoria que motiva nossa avaliação experimental.

O denominador comum das três famílias é o tratamento da sessão como agregado de *features*, e não como entidade raciocinável.

2.3. Modelagem de Sessão em Detecção de Anomalias

A meta-análise de Odusami et al. [11] sobre setenta e cinco estudos em detecção de DDoS de camada de aplicação fornece a evidência quantitativa mais clara sobre como a sessão é tratada. Em quarenta e sete por cento dos métodos catalogados, *features* extraídas de sessões compõem o vetor que alimenta o classificador: taxa de requisições por usuário, duração média, contagem de operações por identidade, entre outras. A redução é uniforme. Em nenhum dos estudos a sessão é mantida como objeto com identidade, alvo, comportamento e relações tipadas; ela é convertida em números antes do classificador. Como consequência, qualquer raciocínio sobre identidades reaproveitadas, sobre convergência de *fingerprints* em endpoints, ou sobre padrões que só emergem entre sessões fica fora do alcance do detector.

A literatura industrial de *bot management* reconhece e explora justamente esses padrões. Cloudflare documenta o uso de *fingerprints* JA4 para agrupar sessões aparentemente independentes por similaridade do *stack* TLS, em sua plataforma de Bot Management. DataDome reporta taxas de falso-positivo abaixo de 0,01% em CAPTCHAs servidos, sugerindo que a discriminação *cross-session* é viável em produção. Esses sistemas, entretanto, são proprietários, sem ontologia pública, sem benchmark acadêmico reproduzível e sem

métricas de dano colateral em legítimos formalizadas em literatura revisada. A formalização acadêmica auditável dessas práticas, e em particular a derivação automática de escopo de mitigação a partir de uma regra ontológica explícita, permanece em aberto.

2.4. Posicionamento deste Trabalho

Sintetizando, três fontes delimitam o espaço onde nossa contribuição se inscreve. Primeiro, KGs estáticos construídos a partir de texto [14, 15, 13] não capturam estrutura de tráfego em tempo de execução. Segundo, KGs populados em runtime e classificados com redes neurais [12] entregam veredicto e relatório, mas sem expressão simbólica das relações entre sessões e sem política de mitigação acoplada. Terceiro, detectores estatísticos e de aprendizado de máquina sobre *features* agregadas [10, 9, 8, 11] descartam a estrutura entre sessões antes mesmo do classificador.

Este trabalho ocupa a interseção que esses três grupos deixam vaga: a sessão HTTP modelada como entidade ontológica de primeira classe; o raciocínio sobre relações entre sessões expresso em formalismo simbólico nativo (OWL, SPARQL, SWRL) e auditável; e a derivação automática de escopo de mitigação a partir do discriminador do *cluster* detectado, com avaliação que reporta explicitamente o impacto sobre tráfego legítimo.

3. Abordagem Proposta

3.1. Visão Geral do Sistema

A Figura 1 apresenta a arquitetura geral do arcabouço proposto. O sistema é composto por quatro estágios: (i) ingestão de eventos HTTP do tráfego de aplicação, (ii) elevação dos eventos a instâncias ontológicas no grafo de conhecimento, com sessões como nós persistentes, (iii) execução de regras semânticas sobre o grafo para detecção de ataques nos três tipos modelados, e (iv) geração da cadeia de evidências que acompanha o veredicto.

3.2. Ontologia Centrada em Sessão

Esta subseção define a ontologia OWL proposta. A classe central é **ApplicationSession**, modelada como entidade de primeira classe com as seguintes relações tipadas:

hasIdentity liga uma sessão à identidade observada do cliente. A classe **Identity** é especializada em **Cookie**, **Token** (JWT), **Username** e **TLSFingerprint** (com instâncias JA3, JA4 e suas variantes).




Figura 1: Arquitetura do arcabouço de detecção centrado em sessão.

`targets` liga uma sessão ao *endpoint* alvo. A classe `Endpoint` tem como subclasses `AuthEndpoint`, `APIEndpoint` e `StaticAsset`.

`exhibitsBehavior` liga uma sessão a um perfil comportamental (`UserBehavior` ou `BotBehavior`), com propriedades como duração de conexão, taxa de bytes, entropia de rotas.

`mitigatedBy` liga uma sessão ou ataque a uma política de mitigação aplicável (`RateLimit`, `Challenge`, `Block`), com um atributo `scope` que delimita o domínio de aplicação da política.

`relatedTo` é uma propriedade abstrata que liga sessões entre si quando há evidência observada de coordenação. Trata-se de uma *família de seis sub-propriedades tipadas e ponderadas*, detalhada abaixo.

A *família `relatedTo`*. A relação *cross-session* não é única, mas estruturada em sub-propriedades que refletem fontes distintas de evidência, cada uma com robustez própria a evasão. Formalmente, `relatedTo` é declarada `owl:TransitiveProperty`, e as seguintes sub-propriedades são declaradas via `rdfs:subPropertyOf`, com pesos $w_i \in [0, 1]$ associados:

`relatedByTLSPFingerprint` ($w = 1,0$) — sessões com mesmo *fingerprint* JA4 (ou variantes próximas). Sinal robusto: trocar o *stack* TLS do atacante exige reescrever a infraestrutura.

`relatedByReusedIdentity` ($w = 1,0$) — sessões observadas com *username*, *token* ou cookie reutilizado.

relatedByTemporalPattern ($w = 0,9$) — sessões com cadência, *jitter* ou duração de conexão coerentes; vem da coordenação operacional da *botnet*.

relatedByPayloadSignature ($w = 0,6$) — sessões com tamanho de *payload*, padrão de bytes ou *User-Agent* convergentes (independentes do JA4).

relatedByEndpointConvergence ($w = 0,6$) — sessões atingindo o mesmo *endpoint* exato com mesma frequência.

relatedByNetworkProximity ($w = 0,3$) — sessões com mesmo ASN ou prefixo de IP. Atribuímos peso baixo porque *botnets* modernas (Mirai-derivadas, frotas *cloud*, *residential proxies*) distribuem agressivamente em rede, e os *proxies residenciais* de operadora móvel compartilham CGN com tráfego legítimo. Esse sinal entra como reforço quando aparece, não como pré-requisito.

Quando o *pipeline* popula o grafo, cada sub-propriedade é instanciada independentemente conforme a evidência específica observada. Duas sessões podem estar ligadas por uma, várias ou todas as sub-propriedades. A regra de detecção, descrita em §3.4, opera por *soma ponderada* das evidências, não por simples disjunção.

Hierarquia de ataques.. A classe abstrata **ApplicationLayerAttack** comporta a subclasse **SlowHTTPDoSFamilly**, que por sua vez se especializa em **ConnectionExhaustionAttack** (variantes *connection-holding*: Slowloris, slow body, slow read) e **CoordinatedHTTPFlood** (variantes *rate-based*: HULK, GoldenEye, HTTP/2 Rapid Reset, CONTINUATION Flood). Ambas compartilham a propriedade comum **exhibitsCrossSessionStructure**, que se torna verdadeira quando a soma ponderada das sub-relações **relatedBy** excede um limiar (§3.4).

A ontologia também declara, mas não operacionaliza experimentalmente neste trabalho, as classes **CredentialStuffing** (subclasse de **LoginFlood**) e **CoordinatedAPIAbuse**. Ambas compartilham a propriedade **exhibitsCrossSessionStructure** e poderão ser instanciadas em regras específicas em extensões futuras (§6), aproveitando a mesma infraestrutura da família **relatedTo**.

3.3. Construção do Grafo em Tempo de Execução

O *pipeline* de construção opera em três fases:

1. **Extração de entidades.** Para cada requisição HTTP observada, são criadas (ou atualizadas) instâncias de `HTTPRequest`, `ApplicationSession`, `Identity` e `Endpoint`. A identidade é composta: `cookie`, `token` (se observável), `username` (em formulários), e `fingerprint` TLS (JA4 calculado a partir do *handshake*).
2. **População das relações tipadas.** As relações primárias `hasIdentity`, `targets` e `exhibitsBehavior` são instanciadas diretamente a partir dos atributos da requisição. As sub-propriedades da família `relatedTo` são instanciadas independentemente, cada uma a partir de seu sinal específico observado no par de sessões em comparação. Uma nova sessão pode disparar a criação de várias arestas `relatedBy` simultaneamente com sessões anteriores na janela ativa, cada uma capturando uma dimensão distinta de coordenação.
3. **Manutenção de janela.** Sessões e relações ficam ativas no grafo dentro de uma janela operacional configurável (por padrão, $W = 5$ minutos), após a qual são descarregadas para manter o grafo enxuto em ambiente de produção.

O Algoritmo 1 apresenta o pseudocódigo do *pipeline*.

Algorithm 1 Construção do Grafo de Conhecimento em Tempo de Execução

Require: Fluxo de requisições $\mathcal{R}$, ontologia $\mathcal{O}$, janela W

Ensure: Grafo de Conhecimento KG persistente em W

```

1:  $KG \leftarrow \emptyset$ 
2: for cada requisição  $r \in \mathcal{R}$  do
3:    $s \leftarrow \text{ResolverSessao}(r)$ 
4:    $i \leftarrow \text{ResolverIdentidade}(r)$ 
5:    $e \leftarrow \text{ResolverEndpoint}(r.\text{path})$ 
6:    $KG.\text{adicionar}(s, i, e)$ 
7:    $KG.\text{instanciarRelacao}(s, \text{hasIdentity}, i)$ 
8:    $KG.\text{instanciarRelacao}(s, \text{targets}, e)$ 
9:    $KG.\text{ligarSessoesPorIdentidade}(s)$ 
10:   $KG.\text{purgarFora}(W)$ 
11: end for
12: retornar  $KG$ 

```

3.4. Regra de Detecção: *CoordinatedHTTPFlood* sobre soma ponderada

A regra central deste trabalho detecta a especialização **CoordinatedHTTPFlood** da família **SlowHTTPDoSFamily** sobre o grafo populado em tempo de execução. A regra é formulada em SPARQL/SWRL; abaixo, sua estrutura formal.

Seja V_{sess} o conjunto de instâncias **ApplicationSession** ativas na janela W . Para qualquer subconjunto $S \subseteq V_{\text{sess}}$ e um *endpoint* e candidato, defina:

$$\Omega(S) = \sum_{i \in \mathcal{R}} w_i \cdot |\{(s_a, s_b) \in S \times S, s_a \neq s_b : (s_a, \text{relatedBy}_i, s_b) \in E\}| \quad (1)$$

onde $\mathcal{R} = \{\text{TLSFingerprint}, \text{ReusedIdentity}, \text{TemporalPattern}, \text{PayloadSignature}, \text{Endpoint}\}$ e w_i é o peso da sub-propriedade i (definido em §3.2). $\Omega(S)$ é a massa ponderada total de evidência de coordenação interna ao conjunto S .

A regra **CoordinatedHTTPFlood** é satisfeita quando existe S tal que:

1. $|S| \geq k_{\min}$ (cardinalidade mínima);
2. $\forall s \in S : (s, \text{targets}, e) \in E$ (convergência em *endpoint*);
3. $\Omega(S) \geq \tau_{\text{cluster}}$ (massa de coordenação acima do limiar);
4. $\sum_{s \in S} \text{rate}(s, e) \geq \tau_{\text{rate}}$ (taxa agregada acima do limiar);
5. $\forall s \in S : \text{behavior}(s) = \text{BotBehavior}$ (perfil comportamental coerente).

A condição (3) é a contribuição central: o *cluster* se sustenta sobre a *combinação* de sinais, não sobre nenhum identificador isolado. Em particular, $\Omega(S)$ pode exceder τ_{cluster} mesmo quando **relatedByNetworkProximity** é nula (botnet distribuída em ASN), desde que pelo menos uma combinação dos sinais de peso alto seja observada. Inversamente, S com apenas **relatedByNetworkProximity** ativa (sessões compartilhando /24, e.g. CGN de operadora móvel) não satisfaz a regra: $w_{\text{net}} = 0,3$ é insuficiente para atingir τ_{cluster} sem reforço dos sinais de peso alto. Isso é proteção explícita contra falsos positivos em tráfego legítimo concentrado em redes específicas.

Outras classes da ontologia.. As classes **CredentialStuffing** e **CoordinatedAPIAbuse** declaradas em §3.2 comportam regras análogas (com **targets** apontando para **AuthEndpoint** e razão de falha de autenticação para a primeira; **hasIdentity** apontando para **tokens** distintos com convergência **relatedByTLSPFingerprint** para a segunda). A operacionalização e avaliação experimental dessas classes está fora do escopo do presente artigo e fica como direção de extensão imediata (§6).

3.5. Cadeia de Evidência e Explicabilidade

[*Esqueleto.*] Quando uma regra dispara, o motor emite um veredicto acompanhado de uma cadeia de evidência que enumera explicitamente: a regra que disparou, as instâncias ontológicas envolvidas (sessões, identidades, *endpoint*), os valores observados das condições, e a política de mitigação sugerida. A cadeia é exportável em formato JSON-LD e STIX 2.1, compatível com integração em *Security Information and Event Management* (SIEM).

4. Metodologia Experimental

4.1. Cenários de Avaliação por Grau de Distribuição

A hipótese central deste trabalho é que o raciocínio *cross-session* simbólico e ponderado fornece vantagem mensurável sobre ataques distribuídos de Slow HTTP DoS, e que essa vantagem cresce com o **grau de distribuição** da campanha. Para isolar esse efeito, a avaliação é parametrizada por três cenários:

Cenário A: Concentrado. Uma única origem ($K = 1$) gerando N requisições contra um endpoint. Representa o ataque clássico *single-source* de alto volume, no qual nenhuma sub-relação **relatedBy** entre sessões precisa ser instanciada para detecção. **Hipótese:** detectores volumétricos clássicos por IP/sessão alcançam desempenho competitivo neste regime; o ganho da soma ponderada *cross-session* é marginal.

Cenário B: Moderadamente Distribuído. K origens distintas ($10 \leq K \leq 100$) sob coordenação comum atacando o mesmo endpoint, cada uma operando dentro de seus limites individuais de *rate-limit*. Representa botnets pequenas ou operações com proxies limitados. **Hipótese:** *baselines* sobre *features* agregadas começam a perder *recall*; a soma ponderada das sub-relações **relatedBy** mantém detecção via sinais de peso alto (**relatedByTLSPingerprint**, **relatedByTemporalPattern**), mesmo quando **relatedByNetworkProximity** é parcial.

Cenário C: Altamente Distribuído. $K \geq 1000$ origens distintas em campanha de Slow HTTP DoS distribuído, dispersas em centenas a milhares de ASNs e prefixos de IP. Cada sessão individual fica abaixo de qualquer limiar razoável, e **relatedByNetworkProximity** é praticamente nula. **Hipótese:** *baselines* caem para *recall* próximo do aleatório; a soma ponderada preserva detecção precisamente porque depende

dos sinais de peso alto, não da proximidade de rede. **Este é o cenário onde a contribuição se sustenta operacionalmente.**

A *money figure* do paper é a curva de *recall* em função do grau de distribuição K , com os *baselines* caindo de A para C enquanto o arcabouço proposto se mantém.

4.2. Conjunto de Dados

A avaliação primária utiliza **tráfego sintético** gerado pelo *pipeline* Python que acompanha este trabalho. A geração parametriza, para cada cenário: número de sessões legítimas concorrentes, número K de origens da campanha, distribuição de identidades por origem, dispersão em ASN e prefixo de IP, janela temporal, e perfil específico do ataque distribuído de Slow HTTP DoS (proporção de variantes **ConnectionExhaustionAttack** e **CoordinatedHTTPFlood**). Como avaliação secundária, são usados subconjuntos de *datasets* públicos com Slowloris e variantes: CICIDS2017 e CIC-DDoS2019. Para comparação direta com KLAGÉ [12], que reporta $F_1 = 84,1\%$ em DDoS Slowloris, RT-IoT2022 e CIC-IoT2023 são usados como *datasets* terciários, com extração de *features* alinhada à definição da ontologia. Dados reais anonimizados de operação ficam como direção futura sujeita a aprovação ética.

4.3. Configuração Experimental

A configuração descreve o ambiente experimental (*hardware*, *software*, parâmetros), os procedimentos de calibração dos pesos w_i e do limiar τ_{cluster} por cenário, e a janela W de manutenção do grafo. Cada combinação (cenário, configuração de ablação) é executada $n \geq 30$ vezes com *seeds* diferentes para permitir estimação de intervalos de confiança.

4.4. Baselines

A comparação experimental é feita contra três *baselines* acadêmicos, todos consumindo o mesmo conjunto subjacente de atributos de tráfego:

- **Perfilamento estatístico** (aproximação de Fernandes et al. [10]): PCA sobre estatísticas agregadas de sessão.
- **Matriz de comportamento** (aproximação de Bharathi e Sukanesh [9]): k -means sobre matriz de *features* por sessão.

- **Aprendizado de máquina supervisionado** (aproximação de Kemp et al. [8]): Random Forest e SVM sobre o mesmo vetor de *features* de sessão.

Adicionalmente, quando comparado em RT-IoT2022 e CIC-IoT2023, o arcabouço é confrontado com os resultados publicados de KLAGÉ [12] sobre o mesmo *dataset* e ataque (DDoS Slowloris). A escolha desses *baselines* é deliberada: cada um representa um ponto distinto no espaço de prior art (estatística, ML clássico, KG com classificador neural), e todos consomem o mesmo material subjacente que nosso arcabouço, mas em representação diferente.

4.5. Métricas de Avaliação

Quatro famílias de métricas são reportadas:

1. **Métricas padrão de classificação** por cenário: precisão, *recall*, F1, AUC, FPR.
2. **Recall por campanha** (não por sessão): para cada campanha coordenada instrumentada no *dataset*, qual fração foi detectada como pertencente à campanha (e não apenas sessões individuais isoladas). Captura diretamente o ganho do raciocínio *cross-session*.
3. **Dano colateral em tráfego legítimo**: fração do tráfego legítimo que cai dentro do escopo derivado da mitigação produzida pelo veredicto. Métrica auto-reportada por produtos comerciais de *bot management* (e.g. DataDome, que afirma $FPR < 0,01\%$) sem benchmark acadêmico público e, até onde verificamos, não usada sistematicamente na literatura acadêmica de detecção de Camada 7.
4. **Qualidade da explicação**: análise qualitativa das cadeias de evidência geradas, em termos de completude (cita todas as sessões correlacionadas e suas sub-relações ativadas) e acionabilidade (escopo de mitigação derivado coerente com o discriminador do *cluster*).

4.6. Análise de Ablação

A análise central isola a contribuição de cada componente do arcabouço em quatro configurações:

- (a) *Baseline* ML sem ontologia, alimentado pelas mesmas *features* agregadas de sessão.

- (b) Arcabouço com ontologia mas *sem nenhuma* sub-relação `relatedBy` (sessões tratadas como nós isolados).
- (c) Arcabouço com ontologia e *apenas* `relatedByNetworkProximity` ativa (raciocínio *cross-session* restrito ao sinal de peso baixo, simulando o que um detector ingênuo baseado em ASN/prefixo conseguiria).
- (d) Arcabouço completo com todas as seis sub-relações ponderadas.

A diferença entre (a) e (d) é a contribuição total da abordagem. A diferença entre (b) e (d) é o ganho específico de qualquer raciocínio *cross-session* simbólico. A diferença entre (c) e (d) — introduzida especificamente nesta versão — isola o ganho dos sinais de peso alto (`relatedByTLSPFingerprint`, `relatedByReusedIdentity`, `relatedByTemporalPattern`) sobre o sinal de proximidade de rede, evidenciando empiricamente por que ASN e prefixo de IP, embora visíveis no grafo, não bastam contra botnets distribuídas. Esperamos que (c) tenha desempenho próximo a (b) no Cenário C (alta dispersão de rede); que (d) seja substancialmente superior a (c) em B e C; e que (a) seja superado por (d) em todos os cenários sem prejuízo de explicabilidade.

5. Resultados e Discussão

5.1. Desempenho Geral por Cenário

Tabela comparativa de F1, FPR, AUC e dano colateral em tráfego legítimo contra os três *baselines* acadêmicos, reportada separadamente para cada cenário de distribuição (A, B, C), com intervalos de confiança. Em RT-IoT2022 e CIC-IoT2023, comparação adicional com os resultados publicados de KLAGÉ [12].

5.2. Curva de Recall por Grau de Distribuição

Figura central do paper: *recall* de cada método plotado em função do grau de distribuição K da campanha. A previsão é uma curva descendente íngreme para os *baselines* entre $K = 100$ e $K = 1000$, enquanto o arcabouço completo (configuração (d) da ablação) mantém *recall* estável precisamente porque depende dos sinais de peso alto, não da proximidade de rede.

5.3. Análise por Sub-Relação *relatedBy*

Para cada um dos cenários, decomposição da contribuição relativa de cada sub-relação à massa ponderada $\Omega(S)$ da Equação 1 que sustentou o disparo da regra. A hipótese a validar é que (i) `relatedByTLSPFingerprint` e `relatedByTemporalPattern` dominam a massa de evidência em todos os cenários; (ii) `relatedByReusedIdentity` contribui significativamente quando a campanha reutiliza credenciais ou tokens, sendo nula caso contrário; (iii) `relatedByNetworkProximity` contribui de modo significativo apenas no Cenário A (concentrado) e cai para próximo de zero no Cenário C; (iv) `relatedByPayloadSignature` e `relatedByEndpointConvergence` oferecem reforço médio em todos os cenários.

5.4. Análise da Vantagem Cross-Session

Medida, no Cenário C, da fração de campanhas distribuídas de Slow HTTP DoS detectadas como tal (e não apenas sessões individuais isoladas) pelo arcabouço completo em comparação aos *baselines* e às configurações intermediárias de ablação. A hipótese a validar é que o ganho de (d) sobre (c) é dominante em C e marginal em A, evidenciando que a expressividade refinada da família `relatedTo` ponderada é precisamente o que sustenta a detecção quando o atacante distribui a operação por muitos ASNs e prefixos.

5.5. Dano Colateral em Tráfego Legítimo

Medida, para cada configuração de ablação, da fração de tráfego legítimo que cai dentro do escopo da mitigação derivada pelo veredicto. Para (a), o escopo tipicamente colapsa para o endpoint inteiro (controle global). Para (d), o escopo é o discriminador do *cluster*, tipicamente o par (*fingerprint TLS*, *padrão de endpoint*) eventualmente reforçado pelo padrão temporal. Hipótese: a fração de legítimos afetada por (a) é uma a duas ordens de grandeza maior que por (d).

5.6. Avaliação da Qualidade da Explicação

Análise qualitativa da amostragem de cadeias de evidência geradas, em termos de (i) completude (todas as sub-relações ativas com seus pesos, todas as sessões do *cluster*, o discriminador derivado, o escopo de mitigação proposto); (ii) acionabilidade (um analista lendo a cadeia pode decidir a ação em segundos, não em minutos). Se viável, estudo com analistas de segurança.

5.7. Significância Estatística

Testes pareados (*paired t-test*, Wilcoxon) sobre as $n \geq 30$ execuções por cenário, com correção de Bonferroni para múltiplas comparações entre métodos.

5.8. Limitações

[*Esqueleto.*] Três limitações principais devem ser declaradas explicitamente:

1. **Vantagem regime-específica:** para ataques *single-source* de alto volume (Cenário A), métodos baseados em limiares estatísticos por IP ou por sessão alcançam desempenho comparável; o ganho marginal do raciocínio *cross-session* é pequeno nesse regime. O ganho cresce com o grau de distribuição da campanha. Este artigo não substitui defesas volumétricas; complementa-as.
2. **Dependência de identificação de sessão e identidade:** a abordagem assume capacidade de extrair sessões, identidades e *fingerprints* TLS dos eventos de tráfego. Em ambientes onde essa instrumentação é parcial ou ruidosa, o desempenho degrada.
3. **Custo de manutenção do grafo** em produção, sensibilidade ao parâmetro W (janela operacional), e generalização para protocolos além de HTTP (TLS *handshake*, DNS) ficam como direções de extensão.

6. Conclusão

Este artigo propôs um arcabouço de grafos de conhecimento centrado na sessão HTTP como entidade ontológica de primeira classe, com quatro componentes principais: (i) ontologia OWL alinhada a STIX 2.1 e MITRE ATT&CK, com a família *SlowHTTPDoSFamily* e a família ponderada *relatedTo* de seis sub-propriedades tipadas; (ii) *pipeline* de construção do grafo em tempo de execução, com cada sub-relação *relatedBy* instanciada independentemente; (iii) regra de detecção *CoordinatedHTTPFlood* formulada em SPARQL/SWRL sobre a soma ponderada das sub-relações, com cadeia de evidência simbólica acoplada à derivação automática de escopo de mitigação; (iv) avaliação parametrizada pelo grau de distribuição, com ablação por subgrupo de sinais e métrica de dano colateral em tráfego legítimo. A defensabilidade da abordagem se sustenta sobre o reconhecimento explícito de que botnets modernas distribuem agressivamente em ASN e prefixo de IP,

o que torna a proximidade de rede um sinal auxiliar e atribui o peso decisivo aos sinais de *fingerprint* TLS, identidade reaproveitada e padrão temporal.

Direções futuras imediatas incluem: (i) a operacionalização experimental das classes `CredentialStuffing` (subclasse de `LoginFlood`) e `CoordinatedAPIAbuse`, já formalizadas na ontologia mas fora do escopo experimental atual, que reaproveitam a mesma família `relatedTo` ponderada; (ii) a extensão da ontologia para outros protocolos de aplicação (DNS, TLS *handshake*, gRPC); (iii) a integração com plataformas SOAR para resposta automatizada a partir da cadeia de evidência exportada; (iv) a avaliação em ambientes de produção com dados reais anonimizados, sob aprovação ética; (v) estudos com analistas de segurança para validação operacional das cadeias de evidência geradas; e (vi) a investigação do efeito de *fingerprints* TLS ofuscados (atacantes que randomizam ativamente o *handshake*) sobre o desempenho do arcabouço, com hipótese a priori de que sinais de peso alto remanescentes (identidade reaproveitada, padrão temporal) compensam parcialmente a perda.

Referências

- [1] N. Tripathi, N. Hubballi, Application layer denial-of-service attacks and defense mechanisms: A survey, ACM Computing Surveys 54 (4) (2021) 1–33. doi:10.1145/3448291.
- [2] Cloudflare, HTTP/2 zero-day vulnerability results in record-breaking DDoS attacks, Cloudflare Blog (Oct. 2023).
URL <https://blog.cloudflare.com/zero-day-rapid-reset-http2-record-breaking-ddos-attack/>
- [3] Google Cloud, How it works: The novel HTTP/2 ‘Rapid Reset’ DDoS attack, Google Cloud Blog, google reports record-breaking peak of 398 million requests per second mitigated (Oct. 2023).
URL <https://cloud.google.com/blog/products/identity-security/how-it-works-the-novel-http2-rapid-reset-ddos-attack>
- [4] MITRE Corporation, CVE-2023-44487: HTTP/2 rapid reset attack, National Vulnerability Database, disclosed October 10, 2023; coordinated disclosure across multiple HTTP/2 implementations (2023).
URL <https://nvd.nist.gov/vuln/detail/CVE-2023-44487>
- [5] Cloudflare, Hyper-volumetric DDoS attacks skyrocket: Cloudflare’s 2025 Q2 DDoS threat report, Cloudflare Blog, reports 6,500+ hyper-volumetric attacks in Q2 2025 (avg. 71/day); HTTP DDoS grew 129%

- year-over-year (2025).
URL <https://blog.cloudflare.com/ddos-threat-report-for-2025-q2/>
- [6] Cloudflare, Targeted by 20.5 million DDoS attacks, up 358% year-over-year: Cloudflare’s 2025 Q1 DDoS threat report, Cloudflare Blog (2025).
URL <https://blog.cloudflare.com/ddos-threat-report-for-2025-q1/>
 - [7] E. Cambiaso, G. Papaleo, G. Chiola, M. Aiello, Slow DoS attacks: Definition and categorisation, in: *International Journal of Trust Management in Computing and Communications*, Vol. 1, Inderscience, 2013, pp. 300–319. doi:10.1504/IJTMCC.2013.056440.
 - [8] C. Kemp, C. Calvert, T. M. Khoshgoftaar, J. L. Leevy, An approach to application-layer DoS detection, *Journal of Big Data* 10 (1) (2023) 22. doi:10.1186/s40537-023-00699-3.
 - [9] R. Bharathi, R. Sukanesh, A PCA based framework for detection of application layer DDoS attacks, *WSEAS Transactions on Information Science and Applications* 9 (12) (2012) 389–398.
 - [10] G. Fernandes Jr., J. J. P. C. Rodrigues, M. L. Proença Jr., Autonomous profile-based anomaly detection system using principal component analysis and flow analysis, *Applied Soft Computing* 34 (2015) 513–525. doi:10.1016/j.asoc.2015.05.019.
 - [11] M. Odusami, S. Misra, O. Abayomi-Alli, A. Abayomi-Alli, L. Fernández-Sanz, A survey and meta-analysis of application-layer distributed denial-of-service attack, *International Journal of Communication Systems* 33 (18) (2020) e4603. doi:10.1002/dac.4603.
 - [12] L. Belcastro, C. Carlucci, C. Cosentino, P. Liò, F. Marozzo, Enhancing network security using knowledge graphs and large language models for explainable threat detection, *Future Generation Computer Systems* 176 (2026) 108160, published online October 2025; received 29 April 2025; accepted 20 September 2025. doi:10.1016/j.future.2025.108160.
 - [13] K. Liu, F. Wang, Z. Ding, S. Liang, Z. Yu, Y. Zhou, Recent progress of using knowledge graph for cybersecurity, *Electronics* 11 (15) (2022) 2287. doi:10.3390/electronics11152287.

- [14] Y. Jia, Y. Qi, H. Shang, R. Jiang, A. Li, A practical approach to constructing a knowledge graph for cybersecurity, *Engineering* 4 (1) (2018) 53–60. doi:10.1016/j.eng.2018.01.004.
- [15] V. Bonagiri, P. Priyadharshini, P. PanneerSelvi, S. Sahitya, R. Swamy, P. Varalakshmi, Practical applications of cybersecurity: A research paper on knowledge graphs for real-world security solutions, in: 2024 4th Asian Conference on Innovation in Technology (ASIANCON), IEEE, 2024. doi:10.1109/ASIANCON62057.2024.10838144.

Apêndice A. Detalhes da Ontologia

[Esqueleto.] A ontologia OWL completa será disponibilizada em formato Turtle e RDF/XML no repositório do projeto.

Apêndice B. Reprodutibilidade

[Esqueleto.] Código-fonte, *datasets* sintéticos e *scripts* experimentais serão disponibilizados em repositório público após a aceitação do artigo, sob licença permissiva.